

東京工業大学工学部

学士論文

一つ以上の参照点を考慮した
物体移動動作の学習と再現に関する研究

指導教員 長谷川 修 准教授

平成28年2月

提出者

学科 情報工学科

学籍番号 12_06181

氏名 菰田 徹也

指導教員認定印		
学科長認定印		

一つ以上の参照点を考慮した 物体移動動作の学習と再現に関する研究

指導教員 長谷川 修 准教授

情報工学科

12_06181 菰田 徹也

人間の生活環境で活動する汎用ロボットを実現するためには、ロボットが人間とのインタラクションを通じて動作を学習する能力を持つことが望ましく、その実現を目指した研究分野の1つとして模倣学習がある。しかし、模倣学習の多くの先行研究では、教示動作の目標位置、すなわちその動作が目標とする最終状態について教示者とロボット間で既知で共有されているという前提に立っている。そこで本研究では、環境中の一つ以上の参照点との位置関係に応じて目標位置が決定されるような物体移動動作を教示し、着目している参照点及び動作の目標位置と参照点との位置関係を推定し、再現する手法を提案する。

提案手法では、初めに環境中の参照点それぞれに学習モデルとしてガウスモデルを生成する。この際環境中の各物体の位置を参照点に含めると同時に任意の物体間の重心位置も参照点として考慮することで複数の物体の位置関係を考慮した動作の学習を可能にしている。学習時には教示された物体移動動作を各参照点を原点とした相対位置に変換し、個々の座標系に応じた線形変換を行ったうえで各モデルを更新する。再現時には学習されたモデルから最尤推定によって教示者が意図していたと推定される参照点を選択してベクトルを生成し、参照点と座標系に応じた逆線形変換を行うことで動作の目標位置を推定する。

また、学習した確率モデルからの生起確率を用いることで、新たな例示動作が既学習動作のいずれに相当するかを識別することも可能になる。

提案手法の有効性を検証するため、提案手法を用いて学習させた動作を学習時と異なる初期環境で再現、識別させる実験を行った。結果として、複数の参照点間の相対的な位置関係を考慮した動作を学習できていることが示された。

今後の課題としては、複数の段階を持つより高度な動作の学習手法や、目標位置や被動作物体の決定時に位置情報以外の特徴量を考慮できるより一般的な学習手法の考察が挙げられる。

目 次

第1章	序論	1
1.1	背景	1
1.2	関連研究	2
1.3	本論文の構成	3
第2章	従来手法	4
2.1	問題設定と定義	4
2.2	従来手法の概要	4
第3章	提案手法	7
3.1	従来手法との相違点	7
3.2	提案手法の概要	7
3.3	動作学習	8
3.4	動作再現	9
3.5	動作識別	10
第4章	実験と考察	12
4.1	実験環境, 前提	12
4.2	動作再現	13
4.3	動作識別	17
第5章	結論	19
5.1	結びと課題	19
	謝辞	20
	参考文献	20
付録 A	動作再現実験における実験結果	23
付録 B	動作再現における観点推定の成否の判定	24

第1章

序論

1.1 背景

近年のロボット技術の発展により，人間の生活環境で活躍する汎用ロボットの実現に向けた様々な研究が行われている．汎用ロボットとは，工場などで作業を行うようなあらかじめプログラムされた動作を繰り返すものではなく，環境との相互作用によって適切な行動を学習，選択して実行できる能力を持ったロボットのことを指す．特に，人間がロボットに動作を見せて学習させるなど人間とのインタラクションを通じて動作の方法や内容を適応的に学習する能力を持たせることで，より直感的に人間がロボットを操作することが可能になることが期待される．また，環境や動作指示者などの状況に応じて適切な動作を適切に行えるような，気が利くロボットの実現に向けた応用も期待できる．

人間とのインタラクションを通じて学習を行う手法の研究の1つとして模倣学習が挙げられる．模倣学習とはロボットに対し，タスクや動作をあらかじめプログラムするのではなく，ロボットの腕を直接操作したり，人間の動作をカメラなどを通じて視覚的に与えたりといった方法で動作を教示し，その挙動を模倣することでタスクや動作を学習する手法を研究する分野であり，近年様々な研究が行われている[12]-[18]．中岡[9]は，教示した人の舞踊動作から四肢の長さや関節角などを考慮した模倣学習を行い，同時に安定した姿勢を保ち直立を維持した状態でロボットに舞踊動作を模倣させる研究を行った．このようにロボットに対し，教示動作と類似した動作を単純に再現させる手法としての模倣学習はある程度成功している．一方，特定のタスクを達成させることを目的とした模倣学習も数多く研究されている．Schaal[11]は，バネマスダンパ系の運動方程式で表される運動モデルのパラメータを教示動作から学習することで，ドラムを演奏するなどの周期運動や，ラケットでボールを打つなどの到達運動の再現を行っている．このように，目標位置が既知で教示者とロボットの間で共通に認識されている，すなわち動作の目的は既知であるという前提で，その目標位置までの動作軌跡などを扱う研究は多く存在する．

一方で，動作を学習する過程においては，動作の目的の獲得方法自体も重要

であると考えられる．例えばレストランで給仕するロボットに，コーヒーを客の前に運ぶという動作を教示して再現させることを考える．動作教示を行った時点でキッチンに置かれているコーヒーの入ったコップを，その時点でテーブルの一角に座る客の前に動かす動作を見せた場合，単純に教示動作からコップの最終位置を把握したとしても，それはそのテーブルの一角という場所に動かすことが重要なのか，その座っている客の前に動かすことが重要なかが理解できていなければ，客の座る位置やテーブルの位置などの環境が変わった場合に教示者の意図に正しく沿った動作が再現できない．このような問題を解決するためには，教示された動作の目的，すなわち教示者の動作意図をロボットが理解しなければならない．また，動作教示の煩わしさを軽減し，人とロボットのインタラクションを円滑にするためには，そのような動作の目標位置などの教示者の内包する動作意図に関する情報は明示的に与えるより，教示動作からロボットが推測し，教示者は教示動作を見せるだけでよくなることが望ましい．そのためには，教示者の動作意図はロボット自身が教示動作から推定する機構を持つ必要がある．

このような背景から，本研究では教示者の動作から動作意図を把握し，意図を汲み取った動作を再現できるような気が利くロボットの実現に向けた研究として，一つ以上の参照点との相対的な位置関係に応じて目標位置が決定する物体移動動作の教示から，教示者の着目している参照点とそれに対する位置決定の方法を推定する手法を提案する．

1.2 関連研究

1.2.1 学習モデルの設定方法

Calinon ら [1] は，与えられた教示動作から，動作の目標位置や軌跡を決定する基準点となる参照点と，参照点を基準とした変位という2つのパラメータを推定することで，未知の環境においても教示動作に内包された動作意図をくみ取った動作再現が可能であることを示している．参照点とは，例えばコーヒーを客の前に運ぶという動作におけるコップを届ける対象となる客の位置で，変位とは参照点である客の位置に対して前方という位置関係のことを指す．[1] では参照点と変位の推定のための学習モデルの設定方法という観点から，既存研究を以下の3つに大別できるとしている．

1. 教示動作と同数のモデルを生成し，組み合わせて動作を再現する
2. 参照点の候補と同数のモデルを生成し，組み合わせて動作を再現する
3. 1つの学習モデルを用い，パラメータを学習することで動作を再現する

Matsubara ら [3] は障害物をまたいで物体を移動する動作において、障害物の高さごとに変化する軌跡を持つ教示動作から教示動作ごとのモデルを学習し、統合することで未学習の高さを持つ障害物においても適切に動作を再現する手法を提案している。

杉浦ら [4] は動詞の持つ動作概念を人とロボット間で共有することを目標にした研究を行っている。その中で物体移動動作の教示に関して、各オブジェクトの位置を参照点とし、ロボットの視覚空間に対して平行な座標系と、動作開始点方向に軸を設定した座標系を変位の候補として、動作軌跡を生成する隠れマルコフモデル [7] のパラメータと参照点、変位を最尤推定によって学習し、参照点を考慮した動作概念の獲得を行っている。また Dong ら [8] は、動作と参照点の関係である変位を、参照点に到達する、参照点から出発する、位置遷移量が等しい、などの特徴的な数パターンに大別し、動作軌跡を生成している。

1.2.2 関連研究の課題点

これらの研究は参照点と変位の推定方法及び動作軌跡の獲得を目標としており、参照点や変位の候補自体の設定方法に関しては十分な議論がなされていない。とりわけ、これらの手法で考慮されているように参照点を各物体の位置に限定した設定方法では動作の目標位置の学習に十分とは言えず、獲得できない動作が存在すると考えられる。特にこれら従来手法では学習できない動作として、複数の参照点間の相対的な位置関係を考慮した動作が挙げられる。例えばレストランで給仕するロボットに、テーブルの横に椅子を等間隔に並べるという動作を学習させることを考える。教示動作からテーブルを参照点とするだけでは、等間隔にするという動作意図を判断できない。椅子同士が等間隔であるということを理解するためには、2つ以上の椅子の相対的な位置関係によって決定する椅子の間隔を把握する必要があり、そのためには2つ以上の椅子の位置を同時に参照点として考慮する必要がある。

本研究では、これら関連研究で用いられる手法を参考にしつつ、特に複数の物体を参照点として考慮する必要のある動作の学習を可能とし、より多種の動作意図を持つ物体移動動作を学習する方法を提案する。

1.3 本論文の構成

本論文は次のように構成されている。第2章では従来手法の概要と課題について述べ、第3章では提案手法について従来手法と対比する形で述べる。第4章では実験とその結果について述べる。第5章では提案手法の考察と改善点、今後の課題について述べる。

第2章

従来手法

2.1 問題設定と定義

本研究は静的な環境下で教示される物体移動動作から，被移動物体（以下，トラジェクタ）の目標位置の決定に關与する参照点と変位を推定する手法を提案する．そのため本研究では，ある地点に置いてある物体を参照点と変位に従った他の地点に移動するという，初期状態と最終状態の対を動作と定義する．

本文において，参照点を l ，変位を k と表し，参照点と変位の対 $\langle l, k \rangle$ を観点と定義する．また L, K, V をそれぞれ参照点の候補の集合，変位の候補の集合，観点の候補の集合とする．従って本研究の主たる目的は，与えられた教示動作から観点 $\langle l, k \rangle$ を推定し，観点に従った動作を再現することである．

2.2 従来手法の概要

2.2.1 参照点

杉浦ら [4] の手法において，参照点は環境中の物体の位置，トラジェクタの初期位置（動作開始点），画面中央と設定されている．トラジェクタの遷移には，大別すると以下の3種類が存在するとしている．

1. 初期状態に関わらず，トラジェクタの初期位置に対して一定の遷移を行う
2. 初期状態に関わらず，空間上の特定の位置に遷移を行う
3. 他の物体との相対位置に応じて遷移先が変化する

これら3種類の違いについて Fig.2.1 で示す．

Fig.2.1(a) はトラジェクタの初期位置を，Fig.2.1(b) は画面中央を参照点に含めることで，Fig.2.1(c) の特殊な事例として実現できるため，全ての物体移動動作は Fig.2.1(c) のような参照点との相対位置を考慮した目標位置を持つとしている．




Fig. 2.1: トラジェクタ遷移の違い

このような理由から，従来研究では L を各物体の位置，トラジェクタの動作開始点，画面中央に定めている．

2.2.2 変位

特定の参照点に対し，変位の違いによって動作はさらに以下の2種類が存在すると定義されている．

1. 参照点を原点とし，常に一定の相対位置に遷移する
2. 参照点を原点とし，トラジェクタの初期位置に応じて遷移先が変化する

これら2種類の違いについてFig.2.2で示す．

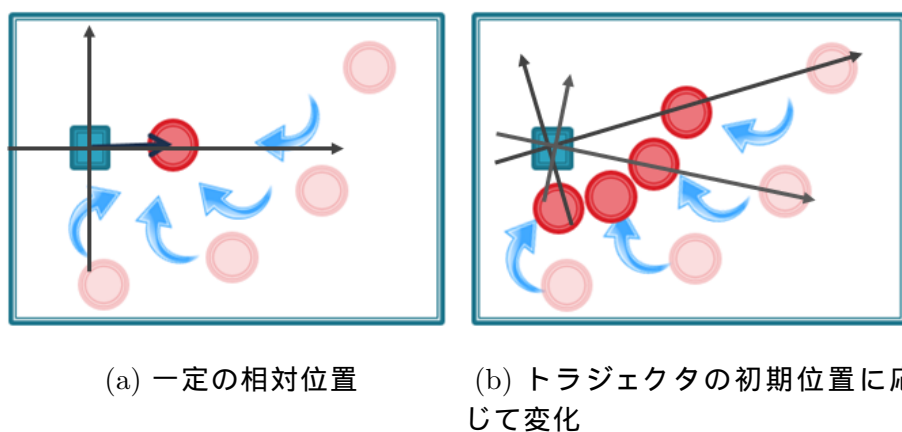


Fig. 2.2: 参照点に対する遷移の違い

Fig.2.2(a) は例えばトラジェクタを物体の右隣に動かすといった動作などを指し、参照点である物体に関して常に相対位置が一定である。Fig.2.2(b) はトラジェクタを物体に近づけるといった動作などを指し、これは参照点となる物体とトラジェクタの初期位置の位置関係によって、参照点からの目標位置の相対位置が変化する。

従来手法ではこれらを判別する変位 k としてそれぞれに異なる座標系を対応させている。例えば Fig.2.2(a) の動作では、参照点を原点として画面に平行な座標系を考慮することで実現することができ、Fig.2.2(b) の動作では、参照点を原点としてトラジェクタの動作開始点に軸を向けた座標系を考慮することで実現することができる。

以下、本研究では変位 k は座標系によって表されとし、Fig.2.2(a) のような画面空間に平行な座標系を恒等座標 k_{id} 、Fig.2.2(b) のような、トラジェクタの動作開始点に向けた軸を持った座標系をランドマーク-トラジェクタ座標 k_{lt} と定義する。

2.2.3 学習，再現

従来手法では教示動作が与えられたとき、以下の式を用いて尤度が最大となる参照点 \hat{l} 、座標系 \hat{k} 、隠れマルコフモデルのパラメータ $\hat{\theta}$ を最尤推定により学習している。

$$(\hat{\theta}, \hat{k}, \hat{l}) = \arg \max_{\theta, k, l} \sum_{i=1}^N \log P(F(Y_i, k, l_i); \theta) \quad (2.2.1)$$

ここで、 Y_i はトラジェクタの位置、速度、加速度の時系列データ、 l_i は参照点、 $F(Y, k, l)$ は座標系 k 、参照点 l としたときのトラジェクタの動作軌道、 $P(F, \theta)$ は動作軌道 F がパラメータ θ の確率モデルから生成される確率である。杉浦らの研究では動作軌道を再現することを目標の一つとしていたため、確率モデルに時系列データを扱える隠れマルコフモデルを使用している。動作再現は 2.2.1 式の最尤推定によって推定されたパラメータ $\hat{\theta}$ を持つ隠れマルコフモデルからトラジェクタ遷移情報の時系列を生成することで実現する。

第3章

提案手法

3.1 従来手法との相違点

従来手法では L を各物体の位置，トラジェクタ動作開始点，画面中央に限定しており，1.2.2 で述べた課題点を解決することができない．その点を踏まえ，提案手法では複数の参照点を学習に利用する手法を導入した．従来手法の拡張で複数の参照点を考慮できるようにするためには，参照点と変位である座標系のいずれかに複数の参照点の情報を保持する機構を導入する必要がある．そこで参照点の候補に各参照点間の重心位置を採用する．また本研究では物体移動動作を初期状態に対する最終状態の決定と定義し，動作軌跡に関しては考慮しないため，学習モデルはより単純なガウスモデルを使用する．

3.2 提案手法の概要

3.2.1 参照点

従来手法で採用されていた各物体位置，トラジェクタの初期位置，画面中央に加えて，提案手法では新たに2つ以上の任意の物体間の重心位置を参照点に含める．すなわち環境中の n 個の物体に対して，参照点は任意の物体間の重心を含めた $2^n + 1$ 個を候補として考慮する．

3.2.2 変位

複数の物体間の相対的な位置関係を考慮する場合，座標系 k の定め方として，参照点を原点とし，他の物体方向に軸を向けた座標系を考慮する必要があると考えられる．そのため提案手法では，従来手法で採用されていた k_{id} ， k_{lt} に，新たに1つの座標系を加えた以下の3種類が存在するとする．

1. 参照点を原点とし，常に一定の相対位置に遷移する
2. 参照点を原点とし，トラジェクタの初期位置に応じて遷移先が変化する
3. 複数の物体の位置関係に応じて遷移先が変化する

これら3種類の違いについて Fig.3.1 で示す．




Fig. 3.1: 参照点に対する遷移の違い

Fig.3.1c の例として，トラジェクタである丸い物体と参照点である三角の物体と四角い物体で，この順序で時計回りに正三角形を構成するよう並べる，という動作が考えられる．その動作においてトラジェクタの目標位置は2つの物体の相対的な位置関係によって決定されるが，図のように2つの物体の重心を参照点として座標系の原点とし，三角あるいは四角い物体の向きに軸をとった座標系 k_{gl} において常に一定の位置を示す．以下，本文中ではFig.3.1c を重心-ランドマーク座標 k_{gl} と定義する．

従って，推定すべき観点 $\langle l, k \rangle$ は $2^n + 1$ 個の参照点 l のうち1つと3種類の座標系 k のうち1つの対として表される．

3.3 動作学習

想定される観点の候補 $\langle l, k \rangle \in V$ のそれぞれに，学習モデルとしてガウスモデルを設定し，その平均，2乗平均，標準偏差をそれぞれ μ_{lk} ， Q_{lk} ， σ_{lk} とする．教示動作が与えられたとき，各観点のガウスモデルを以下のように更新する．

$$v = \text{Norm}_{lk}(\text{Trans}_{lk}(p)) \quad (3.3.1)$$

$$\mu_{lk} \leftarrow \frac{N}{N+1} \mu_{lk} + \frac{1}{N+1} v \quad (3.3.2)$$

$$Q_{lk} \leftarrow \frac{N}{N+1} Q_{lk} + \frac{1}{N+1} v^2 \quad (3.3.3)$$

$$l_k \leftarrow \sqrt{Q_{lk} - \mu_{lk}^2} \quad (3.3.4)$$

ここで、 p は教示動作の目標位置を指す． Norm_{lk} 、 Trans_{lk} はそれぞれその観点における正規化関数と座標変換を指し、以下の式で与えられる．

$$\text{Trans}_{lk}(v) = \begin{pmatrix} \cos l_{kv} & \sin l_{kv} \\ -\sin l_{kv} & \cos l_{kv} \end{pmatrix} (v - \text{Pos}(l)) \quad (3.3.5)$$

$$\text{Norm}_{lk}(v) = \begin{cases} v & (\text{if } k = k_{id}) \\ \frac{\text{unit}}{|\text{Pos}(r_k) - \text{Pos}(l)|} v & (\text{otherwise}) \end{cases} \quad (3.3.6)$$

ただし、 unit は正規化長を表し、

$$\cos l_{kv} = \frac{(v - \text{Pos}(l)) \cdot (\text{Pos}(r_k) - \text{Pos}(l))}{|v - \text{Pos}(l)| |\text{Pos}(r_k) - \text{Pos}(l)|}$$

であり、 $\text{Pos}(l)$ は参照点 l の位置ベクトルを表す．また r_k は座標系 k が軸を向ける方向を決定する参照点を表す．例えば座標系 k_{lt} の場合、 $r_{k_{lt}}$ はトラジェクタの初期位置を表す．正規化関数の必要性と性質については4.2.2で述べる．

3.4 動作再現

教示動作から学習された各観点 $\langle l, k \rangle$ における確率モデルを用いて、トラジェクタの目標位置 v を以下のように求めることで、学習動作の再現を行う．

$$v = \text{Pos}(\hat{l}) + \text{Trans}^{-1}(\text{Norm}^{-1}(\mu_{\hat{l}\hat{k}})) \quad (3.4.1)$$

$$\langle \hat{l}, \hat{k} \rangle = \arg \min_{k, l} l_k \quad (3.4.2)$$

まず学習された各観点のガウスモデルのうち、最も分散の小さいものを探索する．分散が小さいとは教示動作がその観点に対して常に類似した目標位置に遷移していたことを意味し、教示者が意図した観点である可能性が高いと考えられるためである．選択された観点のガウスモデルの平均を、その観点と再現時の初期環境に応じた正規化と座標変換の逆関数を計算し、初期環境における参照点の位置に平行移動することで再現動作のトラジェクタの目標位置を推定する．Fig.3.2 に、提案手法における動作学習と動作再現の模式図を示す．




Fig. 3.2: 動作学習と動作再現

3.5 動作識別

動作ごとに学習された観点集合 V_t を用いて, 目標位置が p である例示動作の属する動作 $t \in T$ を以下のように推定することで, 例示動作の識別を行う.

$$t = \arg \max_t \text{Probability}(\langle l, k \rangle \in V_t, p) \quad (3.5.1)$$

$$\text{Probability}(\langle l, k \rangle, p) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{|Norm_{lk}(Trans_{lk}(p)) - \mu_{lk}|^2}{2\sigma_{lk}^2} \right) \quad (3.5.2)$$

ここで T は既学習動作の集合を表し, V_t とは動作 t を学習した観点の学習モデルの集合を表す. まず各動作において学習されたガウスモデルから, p が生

起される確率である 3.5.2 式をそれぞれ求め，生起確率が最大となるガウスモデルを持つ動作を識別結果とする．また，3.5.1 式に閾値を設定し，以下のように定義し直すことで，未学習動作の推定が可能になる．

$$t = \begin{cases} \arg \max_t \text{Probability}(V_t, p) & (\max_t \text{Probability}(V_t, p) > \text{Threshold}) \\ t_{unknown} & (otherwise) \end{cases} \quad (3.5.3)$$

ここで， $t_{unknown}$ は未学習動作を表す．

第4章

実験と考察

4.1 実験環境，前提

実験環境として，2次元の有限な擬似連続空間とし，被動作対象であるトラジェクタ(赤)と，参照点となりうる4つの物体(青，橙，緑，黄)が存在する空間内での物体移動動作の学習と再現，識別を行うシミュレータ環境を準備した．被教示者にとって，空間の範囲，トラジェクタや物体の数，位置，観点の種類は既知で教示者と認識を共有しており，各動作における観点については未知であるとし，その観点を教示動作から獲得し，動作の再現と識別を行うことを目標とする．

また本実験において使用した動作の，動作名とその動作におけるトラジェクタの目標位置をまとめた表を Table 4.1 に示す．ただし，Table 4.1 における x, y

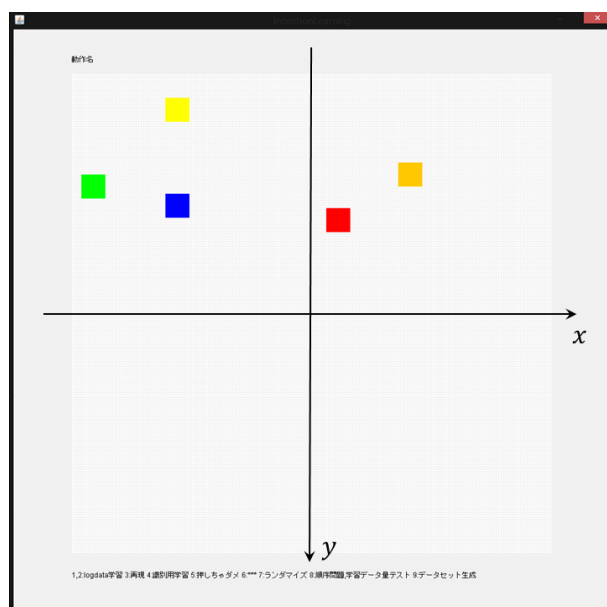


Fig. 4.1: シミュレータ

TABLE 4.1: 動作名とトラジェクタ目標位置の対応表

動作名	トラジェクタ目標位置
T_1 : 赤を中央に移動する	$(x_{center}, y_{center}) + G_{error}$
T_2 : 赤を青の右に移動する	$(x_{blue} + 15, y_{blue}) + G_{error}$
T_3 : 赤を橙に近づける	$\left(\frac{x_{red} + x_{orange}}{2}, \frac{y_{red} + y_{orange}}{2}\right) + G_{error}$
T_4 : 赤を緑から遠ざける	$(2x_{red} - x_{green}, 2y_{red} - y_{green}) + G_{error}$
T_5 : 等間隔に赤黄青と並べる	$(2x_{yellow} - x_{blue}, 2y_{yellow} - y_{blue}) + G_{error}$
T_6 : 時計回りに赤緑青と並べる	$\begin{pmatrix} \cos \frac{\pi}{3} & -\sin \frac{\pi}{3} \\ \sin \frac{\pi}{3} & \cos \frac{\pi}{3} \end{pmatrix} \begin{pmatrix} x_{blue} - x_{green} \\ y_{blue} - y_{green} \end{pmatrix} + \begin{pmatrix} x_{green} \\ y_{green} \end{pmatrix} + G_{error}$

は各物体の，画面中央を原点とし，画面に水平な x 座標と，画面に垂直な y 座標を規定した座標系（以下，画面座標）における座標成分である．また全ての物体は1辺が画面座標における10マス分の正方形とし，空間の範囲は画面座標における x, y 軸ともに $[-200, 200]$ とした． G_{error} とは平均0のガウス分布から生じられる誤差（以下，ガウス誤差）であり，分散の大きさは各実験ごとに設定する． G_{error} は教示誤差を表し，分散が小さいほど正確に与えられた教示動作となる．

4.2 動作再現

提案手法によって動作の学習が適切に行えていることを確認するため，観点が被教示者にとって未知である教示動作を与え，観点を推定し動作を再現する実験を行った．動作再現の実験には Table 4.1 の6動作を使用した．

4.2.1 教示誤差と再現誤差の関係に関する実験

動作教示時に生じた誤差（教示誤差）が，動作再現時に生じる誤差（再現誤差）にどのように影響するか調べるために，教示誤差を変化させながら再現誤差を計測する実験を行った．教示誤差をガウス誤差の分散0.5間隔で0から20まで増やしながらそれぞれ500データ生成し，10データ1セットの一つ抜き法で再現誤差の計算を各教示誤差で計50回ずつ行った．観点推定の成否の判定は計算結果のうち各教示誤差における標準偏差の2.896倍*以上の誤差が生じた再現結果を推定失敗と定めた．Fig.4.2に，そのようにして各再現結果を成功と失敗に分けた観点推定の正答率のグラフを示す．なお，正答率の計算に用いた

*付録B 参照

実験結果については付録 A に示す．また付録 B に，各教示誤差と再現誤差の関係と，判定基準を上記のように定められることの詳細を示す．




Fig. 4.2: 教示誤差と正答率の関係

Fig.4.2 から，教示誤差が十分に小さい場合に，観点の推定が適切に行えていることがわかる．また， T_5 ， T_6 においても十分に正確な教示動作において適切に再現できていることから，複数の参照点を含む動作を適切に学習できていることがわかる．実験に使用した動作のうち， T_1 ， T_3 ， T_4 の正答率が意図した状態と異なり，教示誤差の増加に無関係に再現できているが，これは学習時の遷移ベクトルの正規化関数における正規化長に依るものだと考えられる．正規化長の性質については後述する．また中央に移動する動作は中央に近づく動作とも認識できる等，適切な観点が複数存在する動作に関して誤答率が下がったとも考えられる．

4.2.2 正規化長に関する考察

動作学習時に教示動作に適応される正規化関数 $Norm_{lk}(v)$ は 3.3.6 式で表される．正規化関数は，教示動作から得られた参照点から目標位置までの相対位置ベクトルを，あらかじめ定めた正規化長に正規化する．これは例えば物体に近

づける動作など，距離的な位置関係よりも初期位置からの変化の割合が重視されるような動作や，複数の物体と特定の図形を構成するなどの相似的な配置を目標とする動作の学習に必要な処理である．学習時，教示動作から得られるベクトル v の分散は4.2.1式で与えられる．

$$V(v) = \text{mean}((F_{lk}(v))^2) - (\text{mean}(F_{lk}(v)))^2$$

$$= \left(\frac{\text{unit}}{|Pos(r_k) - Pos(l)|} \right)^2 (\text{mean}(v^2) - (\text{mean}(v))^2) \quad (4.2.1)$$

4.2.1式から，正規化後のベクトルの分散は正規化長の2乗に比例していることが分かる．動作再現時の観点の推定にガウスモデルの分散を利用しているため，正規化長の設定が動作再現の精度に関わることになる．すなわち，正規化長を小さくして $k = k_{lt}, k_{gl}$ におけるモデルの分散を小さくすると $k = k_{lt}, k_{gl}$ である動作を優先的に学習し，正規化長を大きくして $k = k_{lt}, k_{gl}$ における分散を大きくすると $k = k_{id}$ である動作を優先的に学習するため，座標系に応じて再現の正答率に差異が生じたという仮説が立てられる．

4.2.3 正規化長と再現誤差の関係に関する実験

前述の実験において動作ごとに再現誤差が異なるという結果になった原因を，動作学習時に座標系 k_{lt}, k_{gl} にのみ適応した正規化関数における正規化長に起因するものだという仮説を立証するため，正規化長を変化させながら再現誤差を計測する実験を行った．正規化長を1間隔で1から50まで，4間隔で51から199まで増やしながらかそれぞれ教示誤差の分散10で500データ生成し，10データ1セットの一つ抜き法で再現誤差の計算を各教示誤差で計50回ずつ行った．観点推定の成否の判定は同様に計算結果のうち教示誤差における標準偏差の2.896倍[†]以上の誤差が生じた再現結果を推定失敗と定めた．Fig.4.3に，そのようにして各再現結果を成功と失敗に分けた観点推定の正答率のグラフを示す．Fig.4.3bは使用した6動作のうち，座標系が k_{id} であることが期待される動作である T_1 と T_2 の結果を表したものである．結果から， T_2 に関しては仮説通り，正規化長が増加するにつれて再現精度が向上していることが分かる．Fig.4.3cは座標系が k_{lt} であることが期待される動作である T_3 と T_4 の結果を表したものである．結果から，両動作とも仮説通り，正規化長が増加するにつれて再現精度が低下していることが分かる．座標系が k_{gl} であることが期待される動作である T_5 と T_6 も同様に Fig.4.3d に示された結果から，仮説通り，正規化長が増加するにつれて再現精度が低下していることが分かる．また k_{gl} の動作が k_{lt} の動作よりも正規化長の影響を大きく受けているのは，4.2.1式の分母

[†]付録B参照

$|Pos(r_k) - Pos(l)|$ の値が，参照点とトラジェクタ初期位置の距離を表している k_{lt} に対し，重心位置と構成参照点の距離を表している k_{gl} の方が比較的に小さい値となる場合が多いことが原因と考えられる． T_1 が正規化長に関わらず再現精度を維持しているのは，前述のとおり T_1 が k_{id} ， k_{lt} 両方の観点で推定できるためだと考えられる．すなわち，正規化長が小さい場合には k_{lt} として，大きい場合には k_{id} として学習されることが可能であるため，常に高い再現精度を維持していると考えられる．

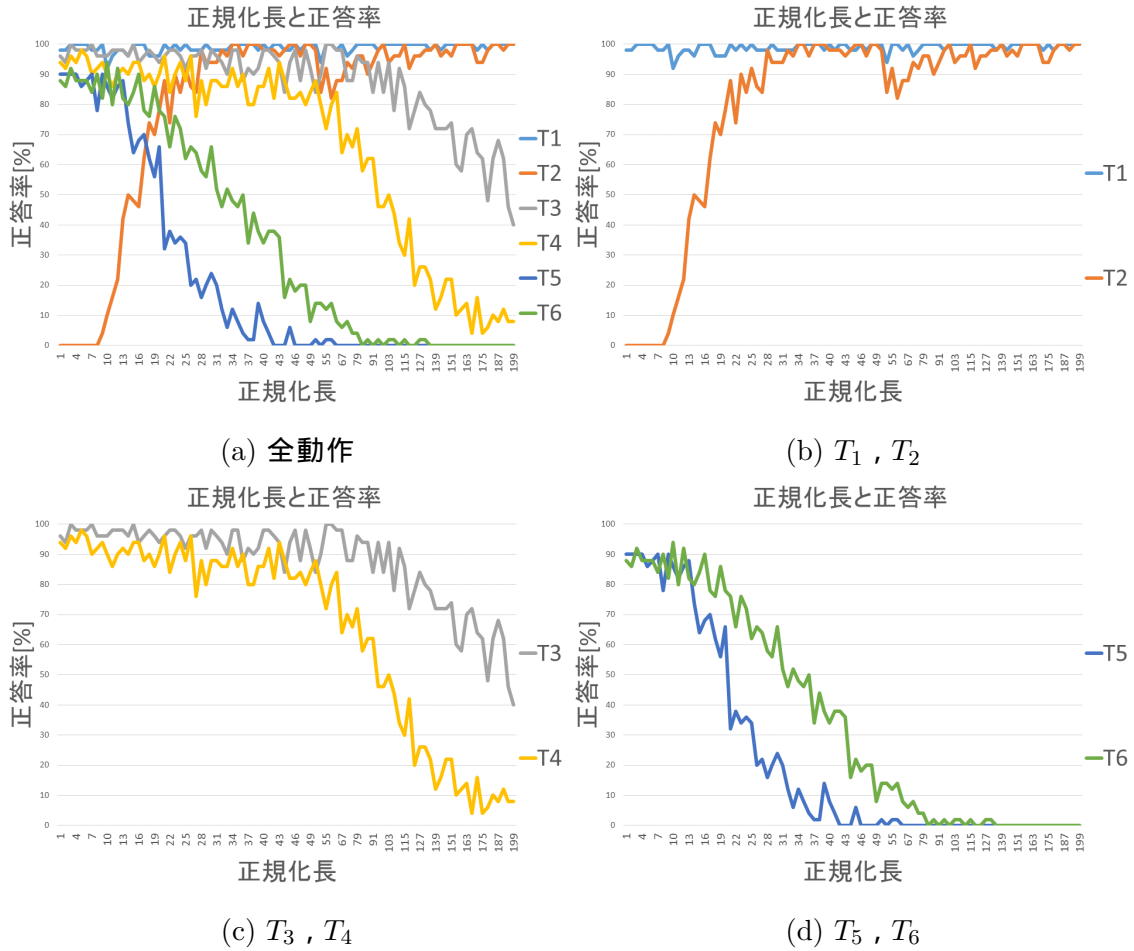


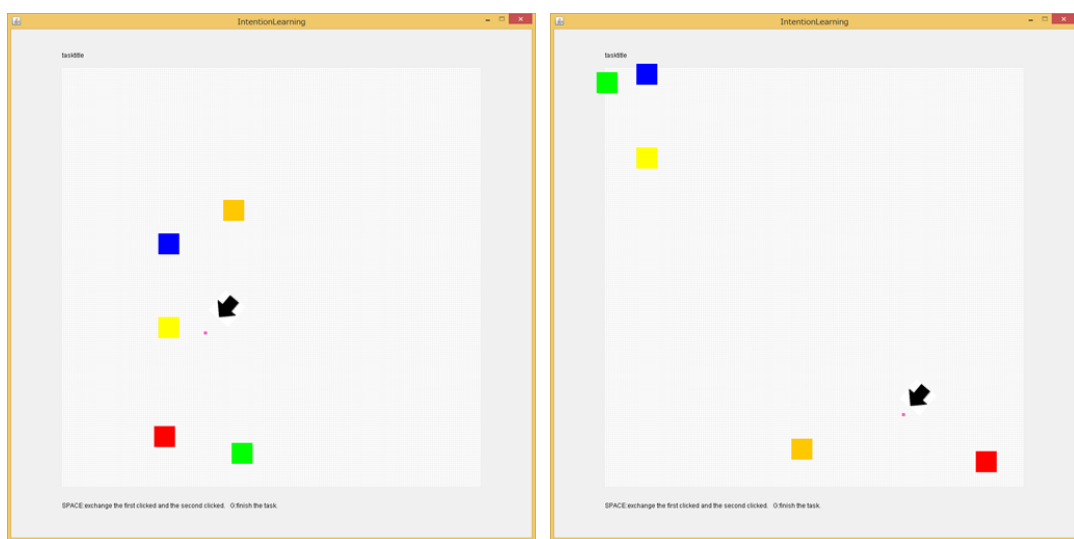
Fig. 4.3: 正規化長と正答率の関係のグラフ

4.3 動作識別

動作名が未知である例示動作を与え、それが既学習動作および未学習動作のうちいずれであるかを推定する実験を行った。既学習動作はTable 4.1の6動作に、各動作に関して変位が等しく参照点を変えて生成した9動作を加えた計15動作とした。また未学習動作として、特定の参照点及び座標系を考慮しない不規則な動作も識別対象とした。各動作において教示動作として分散3のガウス誤差を持つ30データを生成し学習を行った。例示動作は動作再現実験と同様の6動作および未学習動作を使用し、学習済みである6動作はそれぞれ分散10のガウス誤差を持つ100データを生成してテストを行った。未学習動作の判定閾値はガウス分布における95%信頼区間とした。被教示者は例示動作が既学習動作のいずれであるかを答え、判定閾値に満たない動作の場合は未学習動作であると答えるように設計した。Table 4.2に各例示動作の識別正答率を示す。Table 4.2より、学習済みの動作に関して例示動作の識別が適切に行えていることがわかる。また、未学習動作に関しても高い識別精度を示し、既学習動作と未学習動作を適切に区別できていることが分かる。誤識別が生じた初期環境と例示動作の例をFig.4.4に示す。Fig.4.4aは赤を橙に近づける例示動作だが、赤を緑から遠ざける動作だと誤って識別されている。誤識別が生じた例示動作に関しては、ほとんどがこのように人間にとっても適切な動作が判別し難いものであった。またFig.4.4bは唯一既学習動作である例示動作を未学習動作と誤識別した例である。Fig.4.4bが未学習動作だと誤識別された理由については、初期の赤と橙の位置関係に対して小さくない例示誤差が付与し正答が導かれなかったことに加え、他物体が最終位置から遠く離れており、既学習動作であるいずれの動作とも大きく異なったためであると考えられる。

TABLE 4.2: 動作識別の正答率

動作名	正答率
赤を中央に移動する	0.97
赤を青の右に移動する	0.98
赤を橙に近づける	0.93
赤を緑から遠ざける	0.97
等間隔に赤，黄，青と並べる	0.97
時計回りに赤，緑，青と並べる	0.98
未学習動作	0.90



正答: 赤を橙に近づける
 回答: 赤を黄の右に動かす

(a) 誤識別の例 1

正答: 赤を橙に近づける
 回答: 学習していない動作

(b) 誤識別の例 2

Fig. 4.4: 誤識別の例

第5章

結論

5.1 結びと課題

本研究では，物体移動動作において，教示者の動作を考えうる観点の候補ごとの変換を施した上でベクトルの生起確率モデルとして学習することで，教示者の動作意図を把握した目標位置の推定を行うことを目標としていた．その上で参照点の候補に参照点間の重心位置を含めることで，複数の参照点間の位置関係を考慮した物体移動動作の学習を可能にした．提案手法の課題として，全ての重心位置を参照点とすることで考慮する観点の数が物体数に対して指数関数的に増加してしまう点が挙げられる．また，今回扱った各物体の位置情報以外に，形や角度，色などの一般的な特徴量を考慮した観点推定が可能になれば，より高度な動作意図を理解することができると考えられるが，その場合本研究で扱った単純な空間座標としての変換よりも一般的で高次元な座標系を設定する必要がある．それらの問題を解決する方法として，ディープラーニング[19]の手法を用いて教示データから自動的に必要な参照点や座標系を導出することが可能になれば，より広範囲で一般的な学習手法になると考えられる．将来的には，今回の方法で獲得した最終位置をもとに，動作軌跡の認識，推定と再生成を行いたい．また，気が利くロボットの実現に向けて，動作教示の利便性を高めるために，多量に与えられた教示動作のうち学習に適した教示のみを選択して学習することで学習効率を上げる方法や，教示中に誤った動作を認識させてしまった場合，誤教示と判断できる動作を自動的に排除して学習を行う方法についての考察も行いたい．

謝辞

本研究を進めるにあたり，終始多大なるご指導を頂きました長谷川修准教授に心からの感謝の意を表すと共に深く御礼申し上げます。また本研究の遂行及び本論文の執筆に際し，度重なる相談に乗っていただいた平塚迪久さん，並びに日ごろから様々な面でお世話になりました長谷川研究室の皆様に感謝いたします。最後に，日頃励まし支えてくれた家族に，心から感謝いたします。

参考文献

- [1] Sylvain Calinon , Tohid Alizadeh and Darwin G. Caldwell , "On improving the extrapolation capability of task-parameterized movement models" , IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) , 2013
- [2] V. Krueger , D. L. Herzog , S. Baby, A. Ude and D. Kragic , " Learning actions from observations: Primitive-based modeling and grammar " , IEEE Robotics and Automation Magazine , vol. 17,no. 2, pp. 3043 , 2010
- [3] Matsubara Takamitsu , Sang-Ho Hyon and Morimoto Jun , "Learning parametric dynamic movement primitives from multiple demonstrations" , Neural Networks 24.5 : 493-500 , 2011
- [4] Sugiura Koumei , Iwahashi Naoto , Kashioka Hideki and Nakamura Satoshi , "Learning, generation and recognition of motions by reference-point-dependent probabilistic models" Advanced Robotics 25.6-7 : 825-848 , 2011
- [5] 杉浦孔明 , 岩橋直人 , "参照点に依存した確率モデルを用いた連続動作の認識と生成" , 人工知能学会全国大会論文集 : 372-372 , 2008
- [6] 杉浦孔明 , 岩橋直人 , 柏岡秀紀 , 中村哲 , "言語獲得ロボットによる発話理解確率の推定に基づく物体操作対話." 日本ロボット学会誌 28.8 : 978-988 , 2010
- [7] 稲邑哲也 , "HMM と人間の動作認識・教示・生成." 日本ロボット学会誌 29.5 : 419-422 , 2011
- [8] Shuonan Dong , and Brian Williams , "Learning and recognition of hybrid manipulation motions in variable environments using probabilistic flow tubes" , International Journal of Social Robotics 4.4 : 357-368 , 2012
- [9] 中岡慎一郎 , 中澤篤志 , 横井一仁 , 池内克史 , "シンボリックな動作記述を用いた舞踊動作模倣ロボットの実現" , 電子情報通信学会 , PRMU パターン認識・メディア理解 103.390 : 55-60 , 2003

- [10] Jonas Koenemann , Felix Burget and Maren Bennewitz , "Real-time imitation of human whole-body motions by humanoids" , IEEE International Conference on Robotics and Automation (ICRA) , 2014
- [11] Stefan Schaal , "Dynamic movement primitives-a framework for motor control in humans and humanoid robotics" , Adaptive Motion of Animals and Machines. Springer Tokyo , 261-280 , 2006
- [12] Brenna D. Argall , Sonia Chernova , Manuela Veloso , Brett Browning , "A survey of robot learning from demonstration" , Robotics and autonomous systems 57.5 : 469-483 2009
- [13] 臼井和廉 , 波多野拓貴 , 高橋泰岳 , 前田陽一郎 , "人間による呈示動作のバイアスを用いた人型ロボットの模倣学習" , ファジィシステムシンポジウム講演論文集 29 : 836-841 , 2013
- [14] Clemens Eppner , Jürgen Sturm , Margen Bennewitz , Cyrill Stachniss , Wolfram Burgard , "Imitation Learning with Generalized Task Descriptions" , IEEE International Conference on Robotics and Automation, 2009
- [15] Duy Nguyen-Tuong and Jan Peters , "Model learning for robot control: a survey." Cognitive processing 12.4 : 319-340 , 2011
- [16] 中西淳 , Auke Jan Ijspeert , Stefan Schaal , Gordon Cheng , "運動学習プリミティブを用いたロボットの見まね学習." 日本ロボット学会誌 22.2 : 165-170 , 2004
- [17] 田淵一真 , 谷口忠大 , 榎木哲夫 , "模倣学習と強化学習の調和による効率的行動獲得" , 人工知能学会全国大会論文集 : 212-212 , 2006
- [18] S. Mohammad Khansari-Zadeh and Aude Billard , "Learning stable nonlinear dynamical systems with gaussian mixture models" , Robotics, IEEE Transactions on 27.5 : 943-957 , 2011
- [19] 岡谷貴之 , "深層学習" , 講談社 , 2015


付録 A

動作再現実験における実験結果


動作の再現実験における，教示誤差と再現誤差の関係を図 A.1 に示す．ここで，横軸は教示誤差の分散，縦軸は再現誤差の標準偏差を表す．各教示誤差において，教示動作からの学習，再現を行った際の再現誤差を 50 回ずつ実験を行った．適切な観点が選択されている場合，教示誤差と再現誤差の分散が等しくなることが期待される．即ち各グラフにおいて教示誤差 t ，再現誤差 r に関して，

$$r = \sqrt{t}$$


という関係が満たされていることが期待される．A.1 において，付録 B で述べる成否の判別境界を曲線で示した．実際のグラフ中には，境界内で無理関数に従うように見える結果と，境界外で相関が見られ難い結果が存在している．




(a) T_1 : 赤を中央に移動する




(b) T_2 : 赤を青の右に動かす




(c) T_3 : 赤を橙に近づける



(d) T_4 : 赤を緑から遠ざける



(e) T_5 : 等間隔に赤黄青と並べる



(f) T_6 : 時計回りに赤緑青と並べる

Fig. A.1: 教示誤差と再現誤差

付録 B

動作再現における観点推定の成否の判定

教示動作から学習したモデルを用いた動作再現を行う際、教示動作自体に誤差が含まれている場合、一つ抜き法によるテスト時に使用するデータも教示動作の一つであるために必然的に誤差が生じる。そのため一つ抜き法により計算された再現誤差が教示誤差に依るものなのか誤学習に依るものなのかを区別する基準が必要である。ここでは正規分布から生成された誤差を含む教示動作から適切に学習された場合に再現誤差も正規分布に従うことを示し、正規分布の性質から観点推定の成否の基準値を設定する。まず、適切な観点（原点となる参照点と座標系）からの N 回分の各教示動作における目標位置 $\mathbf{p}_n = \{p_{n1}, p_{n2}, \dots, p_{nN}\}$ に対し、 \mathbf{p}_n を用いた一つ抜き法による評価値を次のように求める。

$$Cr(\mathbf{p}_n) = \frac{1}{N} \sum_{n=1}^N F(\mathbf{p}_n | \mathbf{p}_n \setminus \mathbf{p}_n) \quad (\text{B.0.1})$$

ここで B.0.1 式の右辺 $F(\mathbf{p}_n | \mathbf{p}_n \setminus \mathbf{p}_n)$ は、 \mathbf{p}_n を除く $\mathbf{p}_n \setminus \mathbf{p}_n$ を用いて学習し再現を行った結果の目標位置と \mathbf{p}_n の誤差を表す。動作再現は選択された観点に割り当てられた正規分布の平均を出力するので、

$$F(\mathbf{p}_n | \mathbf{p}_n \setminus \mathbf{p}_n) = |\mathbf{p}_n - \text{mean}(\mathbf{p}_n \setminus \mathbf{p}_n)| = \left| \frac{N}{N-1} (\mathbf{p}_n - \text{mean}(\mathbf{p}_n)) \right| \quad (\text{B.0.2})$$

である。ただし $\text{mean}(A)$ は A の平均とする。B.0.2 式を B.0.1 に代入すると

$$Cr(\mathbf{p}_n) = \frac{1}{N} \sum_{n=1}^N \left| \frac{N}{N-1} (\mathbf{p}_n - \text{mean}(\mathbf{p}_n)) \right| = \frac{N}{N-1} \frac{1}{N} \sum_{n=1}^N |(\mathbf{p}_n - \text{mean}(\mathbf{p}_n))| \quad (\text{B.0.3})$$

と整理できる。ここで B.0.3 式の右辺 $|(\mathbf{p}_n - \text{mean}(\mathbf{p}_n))|$ は \mathbf{p}_n の持つガウス誤差と等しいので、

$$\text{mean}(Cr(\mathbf{p}_n)) = \frac{N}{N-1} * \text{mean}\left(\frac{1}{N} \sum_{n=1}^N |(\mathbf{p}_n - \text{mean}(\mathbf{p}_n))|\right) = \frac{N}{N-1} * \text{mean}(|G_{\text{error}}|) \quad (\text{B.0.4})$$

となる． $2 \int_0^\infty G_{error}(v)dv = \sqrt{\frac{2}{\pi}}$ であることから， $Cr(\quad)$ の平均は

$$mean(Cr(\quad)) = \frac{N}{N-1} \sqrt{\frac{2}{\pi}} \quad (B.0.5)$$

と求められる．ただし σ^2 はガウス誤差の分散である．同様に，

$$mean(Cr(\quad)^2) = \left(\frac{N}{N-1}\right)^2 * mean(|G_{error}|^2) = 2 \int_0^\infty \frac{x^2}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \quad (B.0.6)$$

であり，これを計算することで，

$$mean(Cr(\quad)^2) = \left(\frac{N}{N-1}\right)^2 \sigma^2 \quad (B.0.7)$$

が得られる．B.0.5式とB.0.7式から， $Cr(\quad)$ の標準偏差は，

$$\sqrt{V(Cr(\quad))} = \sqrt{mean(Cr(\quad)^2) - (mean(Cr(\quad)))^2} = \frac{N}{N-1} \sqrt{\frac{\pi-2}{\pi}} \quad (B.0.8)$$

と求められる．平均 m ，分散 σ^2 の正規分布に従うデータ x に対して $|x - m| > 3\sigma$ となる確率は99.73%となることが知られている．このようなは，適切な観点でない異なる分布から生起されたとし，観点の推定自体を誤っていると考えることで，観点推定の成否を判定し評価することができる．今回の実験において $\sigma > 0$ であるため，基準値 $border$ を，

$$border = mean(Cr(\quad)) + 3\sqrt{V(Cr(\quad))} = 2.8959 \quad (B.0.9)$$

と定め，これ以上の再現誤差が生じた結果について観点推定失敗と定めた．